Advanced Institute for Artificial Intelligence

Preparação do Ambiente

Advanced Institute for Artificial Intelligence – AI2

https://advancedinstitute.ai

Sistemas Unix

Links e Referências

- https://datasciencepractice.study/
- https://www.datascienceatthecommandline.com/
- https://swcarpentry.github.io/shell-novice
- http://people.duke.edu/~ccc14/duke-hts-2018/cliburn/The_Unix_Shell_02__Working_with_Text.html

Agenda

1. Introdução/Motivação
2. Interação com o SO - Comandos Básicos
3. Gerenciando Processos
4. Manipulação de Arquivos

Motivação

Como cientista de dados, **é quase impossível evitar os sistemas Unix**. Unix vs Windows não é uma questão de preferência como R vs Python; se você não conhece o Unix, **é provável que tenha dificuldades no local de trabalho**. Unix é o **sistema operacional da ciência de dados**, então você precisa saber como usá-lo.

O que é Unix?

> *Os sistemas Unix são caracterizados por um **design modular** que às vezes é chamado de "filosofia Unix". Este conceito implica que o sistema operacional fornece um conjunto de **ferramentas simples**, cada uma desempenhando uma **função limitada e bem definida**, com um sistema de arquivos unificado (o sistema de arquivos Unix) como principal meio de comunicação, e script shell e linguagem de comando (o Unix shell) **para combinar as ferramentas** para realizar **fluxos de trabalho complexos**.*

Wikipedia

Cenários de Uso

Você pode encontrar sistemas Unix como um cientista de dados:

- ao trabalhar na linha de comando usando sistemas operacionais macOS ou Linux,
- ao trabalhar com servidores remotos no data center do seu empregador,
- ao trabalhar com servidores remotos fornecidos pela AWS, Azure, GCP, etc,
- ao trabalhar com servidores Jupyter ou RStudio compartilhados (eles são hospedados em servidores Unix)

Cenários de Uso

Alguns exemplos de uso do Unix para ciência de dados incluem:

- usando `ssh` para se conectar a um servidor de análise remoto
- usando `scp` para mover arquivos entre servidores
- usando um gerenciador de pacotes (por exemplo, `brew`, `apt`, `yum`) para instalar ferramentas de linha de comando
- usando ferramentas de linha de comando para interagir com serviços de terceiros
- usando `wget` para baixar arquivos da internet
- usando `top` para monitorar a utilização de recursos do sistema
- usando `docker` para gerenciar e executar contêineres

Sistema Operacional Linux

O Sistema Operacional (SO) é o programa que controla o computador, servindo de Interface entre o usuário e a máquina. O Sistema Operacional faz isso através de dois componentes: O Kernel e o Shell

- Kernel é o nome dado ao núcleo do Sistema Operacional. É o módulo deste programa que se comunica com o hardware do computador
- Shell é a "fachada" do Sistema Operacional. Essa é a parte do programa que se comunica com o usuário, recebendo seus comandos e repassando-os ao Kernel

Distribuição Linux

- É o nome dado ao conjunto de programas formado pelo Kernel Linux e por mais alguns softwares distintos (como Shells, aplicativos, jogos, utilitários, etc.)
- Várias empresas (ou pessoas) podem agrupar os programas que acham interessantes e criar suas próprias distros
- O Que Há Numa Distribuição?
  - Kernel, shell e ambiente gráfico
    - KDE, Gnome, ABlackBox, WindowMaker, Fluxbox

Sistema Operacional Linux

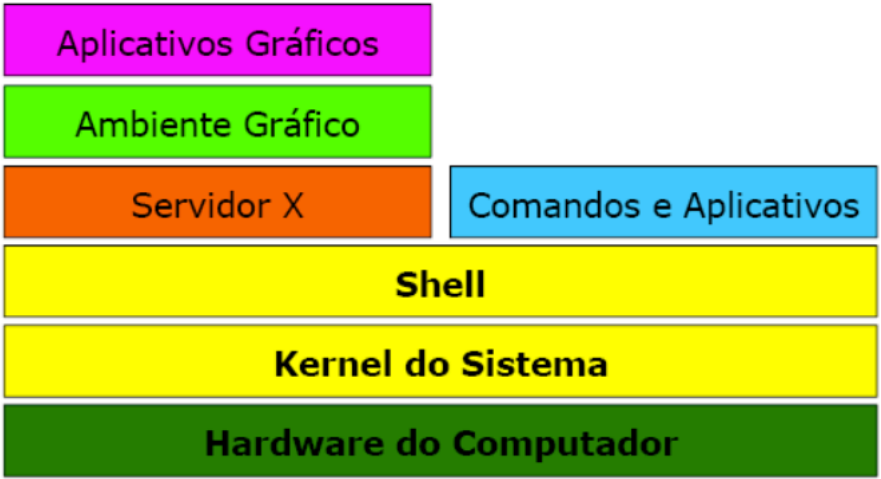

O Shell Unix

- Protege usuários de lidar com as *entranhas* do SO;
- Quando as pessoas dizem "shell" hoje em dia, quase sempre se referem ao **B**ourne **A**gain **SH**ell (**bash**)
- Examplo de um REPL - *Read-Evaluate-Print Loop*.
  1. o shell lê seu comando;
  2. o shell avalia seu comando e calcula a saída;
  3. o shell imprime a saída para o terminal;
  4. o shell imprime um novo prompt, pronto para seu próximo comando;

Sistema Operacional Linux

Comandos de sessão:

- Login: iniciar sessão: Interface Gráfica ou Terminal
- Logoff : sair da sessão
  - `exit`
- Reboot : reinicia o sistema
  - `reboot`
- `poweroff` ou `shutdown -h now` desliga o sistema

Atalhos úteis em uma sessão:

- TAB auto completa comandos
- History mostra a lista de comandos executados
- ! id-histórico executa o comando do histórico com o id id-histórico
- Man mostra ajuda de comandos

Estrutura de arquivos

- Referência a um arquivo/diretório é feita através de um caminho, que é formado da seguinte forma:
- [diretório raiz] [diretório 1] [diretório 2] ... [diretório n] [arquivo]
- Cada um desses itens são separados por uma / (barra) no Linux
- o diretório raiz chama-se / (barra)
  - Exemplo de caminho: `/home/rmcobe/doc/1`
- exemplo de caminho: /home/rmcobe/doc/1

Comandos Básicos - Manipulação do Sistema de Arquivos

- `cd`: Comando para acessar um diretório
- `pwd`: retorna o caminho do diretório desde a raiz /
- `cp`: copia um arquivo ou diretório de uma caminho para outro
- `find`: procurar por arquivos ou diretórios no sistema de arquivos
- `mkdir`: cria um novo diretório
- `mv`: mode um arquivo ou diretório de um caminho para outro
- `ls`: lista um diretório

Comandos Básicos - Manipulação do Sistema de Arquivos

- `rm`: remove um diretório, desde que esteja vazio
- `touch`: cria um arquivo vazio
- `du`: retorna o espaço utilizado por um diretório ou arquivo
- `df`: retorna as partições presentes no sistema
- `tree`: retorna a árvore do sistema
- `chmod`: muda a permissão de arquivos e diretórios

Alguns diretórios possuem notações especiais ou "atalho"

- ~: ao referir-se ao diretório ~ (til), o sistema entende como o diretório pessoal do usuário, ou seja, /home/[usuário], onde [usuário] é o nome de login do usuário atual.
- -: o kernel Linux armazena um histórico dos diretórios que acessamos. O - (hífen) refere-se ao último diretório acessado
- .: o símbolo . (ponto) refere-se ao diretório atual, ou seja, aquele em que estamos trabalhando
- ..: o .. (ponto ponto) refere-se ao diretório acima do qual estamos.

Manipulando Arquivos

No Linux existem três tipos de permissão para definir os acessos a arquivos e diretórios:

- `r` : Permissão de leitura para um arquivo; e permitir listar o conteúdo de um diretório através do comando ls diretório
- `w` : Permissão de gravação e exclusão para um arquivo/diretório.
- `x` : Permissão para executar um arquivo, se for um arquivo binário ou um script; e se for um diretório permitir acesso a ele através do comando cd diretório
- Tais permissões são concedidas aos seguintes papéis de usuário
  - Dono : O proprietário do arquivo ou criador do arquivo
  - Grupo: Usuários que fazem parte do grupo do proprietário
  - Outros: Não são os proprietários e nem fazem parte do grupo

Manipulando Arquivos

Filtros

- `grep` Examina cada linha de dados que recebe da entrada padrão e produz cada linha que contém um padrão especificado de caracteres.
- `sort` Classifica a entrada padrão e produz o resultado classificado na saída padrão
- `uniq` Dado um fluxo de dados classificado da entrada padrão, ele remove linhas de dados duplicadas (ou seja, garante que cada linha seja única).
- `head` Exibe as primeiras linhas de sua entrada. Útil para obter o cabeçalho de um arquivo.
- `tail` Exibe as últimas linhas de sua entrada. Útil para coisas como obter as entradas mais recentes de um arquivo de log.

Variáveis de Ambiente

- `export` : cria uma variável
- `env` : mostra as variáveis criadas
- `unset` : apaga uma variável
- `echo` : mostra o valor atribuído a uma variável

Tipos de processos:

- Processos interativos: são iniciados a partir de uma sessão de usuário no terminal de comandos e são controlados por ele
- Processos em lote (batch): o processo entra em execução e não permite nenhuma interação com o usuário do SO
- Daemons: são processos servidores normalmente executados quando o Linux é inicializado, permanecendo em execução enquanto o sistema estiver em funcionamento esperando em background que outro processo solicite o seu serviço.
    - Utiliza-se o operador & para que o processo execute e libere o terminal

Gerenciando Processos

Pesquisando processos em execução comando ps

- Exibe informações sobre os processos ativos
- `ps` [opções]
- a exibe também informações de outros usuários
- u exibe o nome do usuário e a hora de início do processo
- x exibe também os processos não associados a um terminal de controle
- -p pid exibe o processo cujo número é pid

Gerenciando Processos

kill: finaliza um processo por meio do pid;

- `kill` [opções] [sinal] pid
- -n sinal aplicado ao processo
- -l lista todos os nomes e números de sinais
  - kill -9 1029

Gerenciando Processos

Comandos para exibir informações sobre o computador de forma geral

- `free`: exibe a quantidade de memória livre;
- `lscpu`: exibe informações sobre o CPU

Redirecionamento

- Redirecionamento de saída:
  - $>$ e $>>$
- Redirecionamento de entrada:
  - $<$ e $<<$
  - `sort < arquivo`
- Pipe (|) - redireciona a saída de um comando para a entrada do próximo:
  - `cat arquivo | uniq`

Manipulando Arquivos

cat : concatena arquivos e lista na saida padrão

- Sintaxe: **cat** [opções] parametros
- Parâmetros pode ser uma lista contendo arquivos
- Exemplo de uso: cat arq1.txt arq2.txt
  - Concatena arq1.txt e arq2.txt e exibe na saída padrão
- Outro Exemplo: cat > arq3.txt

Contêineres Docker

Links e Referências

- https://docker-curriculum.com/
- https://docs.microsoft.com/pt-br/visualstudio/docker/tutorials/docker-tutorial

Agenda

- Conceitos e definições
- Arquitetura Docker
- Criação e Manipulação de Contêineres

Definição

- Segregação de processos no mesmo kernel;
- Isolamento máximo possível de todo o resto do ambiente;
- File Systems, criados a partir de uma "imagem";
- Torna a reprodutibilidade muito mais fácil
- Conceitualmente semelhante a máquinas virtuais

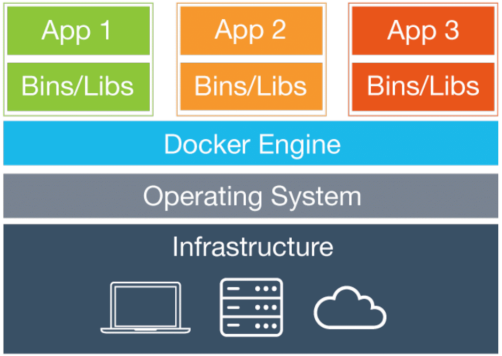

Figure: Aplicações utilizando Contêineres

Vantagens

- Leves porque não contêm um sistema operacional;
- Têm o mesmo desempenho que o código executado no sistema operacional host:
  - Até três vezes mais desempenho do que as máquinas virtuais, quando executados no mesmo hardware).
- Tempo de inicialização em milissegundos (em comparação com minutos para uma máquina virtual).
- Requerem pouca memória RAM
- São definidos usando código
  - Podemos tirar vantagem de sistemas de controle de código como o Git.
- Incentivam o reúso, para que você possa minimizar o retrabalho dispendioso.

Desvantagens

- Sempre são executados no sistema operacional Linux (os contêineres compartilham o sistema operacional do host):
  - Máquinas virtuais podem executar um sistema operacional diferente para cada máquina virtual
- Os contêineres usam isolamento no nível do processo
  - potencialmente menos seguro do que as máquinas virtuais totalmente isoladas

```
> docker run hello-world

Unable to find image 'hello-world:latest' locally
latest: Pulling from library/hello-world
b8dfde127a29: Pull complete
Digest: sha256:f2266cbfc127c960fd30e76b7c792dc23b588c0db76233517e1891a4e357d519
Status: Downloaded newer image for hello-world:latest

Hello from Docker!
This message shows that your installation appears to be working correctly.

...

Share images, automate workflows, and more with a free Docker ID:
 https://hub.docker.com/

For more examples and ideas, visit:
 https://docs.docker.com/get-started/
```

Conceitos

- **Imagem**: um conjunto estático de arquivos binários que armazenam todas as informações necessárias para iniciar um contêiner
- **Contêiner**: um sistema operacional isolado usando conteinerização (neste caso via Docker) para rodar em um sistema operacional host (neste caso MacOS)

Importante

É importante ressaltar que um contêiner é uma instância em execução de uma imagem.

Imagens

- Materialização de um modelo de um sistema de arquivos
- Produzido através de um processo de build;
- Representada por um ou mais arquivos e pode ser armazenada em um repositório como Github;
- O Docker utiliza file systems especiais para otimizar o uso, transferência e armazenamento das imagens, containers e volumes.
  - O principal é o AUFS, que armazena os dados em camadas sobrepostas, e somente a camada mais recente é gravável.

Arquitetura

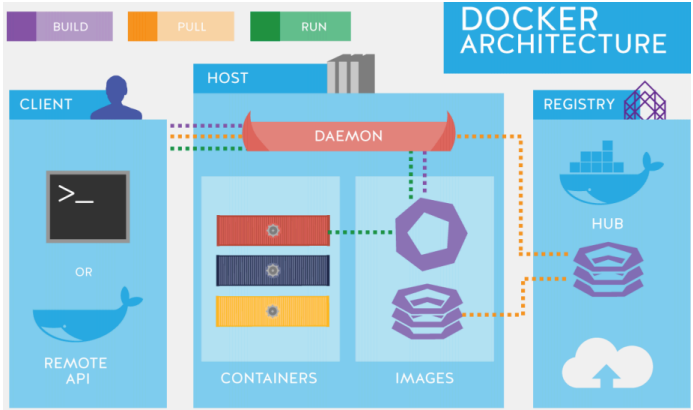

Figure: Arquitetura Docker

Parâmetros de Execução

- Execução Interativa:
  - `--interactive` - isso nos permitirá digitar comandos de forma interativa no contêiner
  - `--tty` - aloca um pseudo-TTY que permitirá que o contêiner imprima sua saída na tela.

```
1  > docker run --interactive --tty ubuntu:20.04 bash
2
3  Unable to find image 'ubuntu:20.04' locally
4  20.04: Pulling from library/ubuntu
5  a70d879fa598: Pull complete
6  c4394a92d1f8: Pull complete
7  10e6159c56c0: Pull complete
8  Digest: sha256:3c9c713e0979e9bd6061ed52ac1e9e1f246c9495aa063619d9d695fb803
       9aa1f
9  Status: Downloaded newer image for ubuntu:20.04
10 root@e2dd9abd3559:/#
```

Parâmetros de Execução

```
root@e2dd9abd3559:/# uname -r
4.19.121-linuxkit

root@e2dd9abd3559:/# cat /etc/lsb-release
DISTRIB_ID=Ubuntu
DISTRIB_RELEASE=20.04
DISTRIB_CODENAME=focal
DISTRIB_DESCRIPTION="Ubuntu 20.04.2 LTS"
```

Principais comandos:

- Listar Imagens:
  - `docker image ls`
- Listar Contêineres
  - `docker ps -a`
- Remover Contêineres/Imagens
  - `docker [image] rm 6f0684d58dca`
- Mapeamento de Volumes
  - `docker run -it -v [host]:[container] ubuntu bash`